



SkinWise

Scelte Cosmetiche Intelligenti

Progetto di Machine Learning

Laurea Triennale in Informatica – Università Degli Studi di Salerno

Docenti:

Prof. Polese Giuseppe

Prof.ssa Caruccio Loredana

Autore:

Katia Perretta (Matricola 0512120888)

Sommario

Descrizione del Problema	2
Analisi Esplorativa dei Dati (EDA)	3
Comprensione del Dataset	3
Analisi del Products Dataset	3
Analisi del Reviews Dataset	5
Integrazione dei due Dataset	6
Limiti	6
Distribuzione dei Dati	6
Distribuzione del Target	6
Distribuzione delle Feature dell'Utente	6
Distribuzione delle Feature dei Prodotti	8
Missing Values	9
Outliers	10
Merge dei Datasets e Selezione delle Features	11
Preprocessing	12
Gestione dei Missing Values	13
Trattamento Outliers	14
Encoding delle Variabili Categoriche	14
Selezione delle Feature	15
Split del Dataset (Train, Validation, Test)	15
Scaling delle Variabili Numeriche	16
Bilanciamento del Training Set	16
Modello e Scelte Progettuali	17
Logistic Regression	17
Random Forest	17
Valutazione Iniziale delle Prestazioni	18
Gestione dello Sbilanciamento	19
SMOTE (Synthetic Minority Over-sampling Technique)	19
Balanced Random Forest	19
Confronto dei Risultati sul Validation Set (LR, RF, LR+SMOTE, BRF)	19
Prestazioni del Modello sul Test Set (LR)	20

Threshold Tuning.....	21
Valutazione delle Soglie sul Validation Set	22
Confronto dei Risultati sul Test Set (LR con diverse soglie)	22
Considerazioni finali e Sviluppi Futuri	23

Descrizione del Problema

Nel settore cosmetico, la selezione di un prodotto adeguato alle caratteristiche individuali dell'utente rappresenta una sfida rilevante. I consumatori si trovano spesso a dover scegliere tra un'elevata varietà di prodotti, facendo affidamento su informazioni generiche fornite dai produttori, recensioni soggettive o su un approccio basato su tentativi ed errori. Questo processo può portare a scelte poco efficaci o non adatte alle specifiche esigenze cutanee, con possibili effetti indesiderati e insoddisfazione da parte dell'utente.

L'obiettivo di questo progetto è affrontare tale problematica mediante un approccio di **Machine Learning**, sviluppando un **modello predittivo in grado di stimare la compatibilità tra un utente e un prodotto cosmetico**. In particolare, il modello mira a prevedere se un determinato prodotto sia adatto o meno a un utente, considerando sia le caratteristiche individuali della persona sia le proprietà del prodotto cosmetico.

Gli **input del modello** includono:

- le **caratteristiche dell'utente**, come ad esempio il tipo di pelle e altre informazioni rilevanti;
- le **caratteristiche del prodotto cosmetico**, tra tipologia di prodotto, brand e altre proprietà descrittive.

L'**output atteso** del modello è una previsione che indichi il grado di compatibilità tra il prodotto e il profilo dell'utente, espressa come un valore binario.

Il progetto, dunque, consiste nello sviluppo di un **sistema di classificazione supervisionata**.

Formalmente, il problema è definito come un **task di classificazione binaria**, in cui ogni istanza è rappresentata da una coppia (*utente, prodotto*). A ciascuna istanza è associata un'etichetta binaria che indica l'esito della compatibilità:

- **1 (compatibile)**: il prodotto risulta adeguato al profilo dell'utente;
- **0 (non compatibile)**: il prodotto non è adeguato al profilo dell'utente.

L'obiettivo è quello di **generalizzare** dai dati di addestramento per fornire previsioni affidabili su nuove coppie utente-prodotto mai osservate in precedenza.

Tale approccio consente di supportare il processo decisionale dell'utente, fornendo una raccomandazione personalizzata e riducendo il rischio di scelte non adeguate.

Le prestazioni del modello vengono valutate tramite metriche appropriate per la classificazione binaria, quali **accuracy, precision, recall e F1-score**, al fine di misurare la capacità del sistema di distinguere correttamente prodotti compatibili e non compatibili. Inoltre, viene analizzata la **confusion matrix**, che consente di esaminare in modo dettagliato la distribuzione delle predizioni

corrette ed errate, fornendo una comprensione più approfondita del comportamento del modello e dei principali tipi di errore commessi.

Analisi Esplorativa dei Dati (EDA)

Comprensione del Dataset

Affinché un dataset possa essere considerato coerente con il problema definito, deve fornire:

- **caratteristiche dell'utente**
- **caratteristiche del prodotto**
- **un segnale di compatibilità (label)**

La fonte dei dati impiegati nel progetto è **Kaggle**, una piattaforma pubblica per la condivisione di dataset e risorse per il machine learning.

I dati scelti (disponibili al link: [Sephora Products and Skincare Reviews](#)) sono organizzati in due file distinti:

- Il primo file (**Products Dataset**) è dedicato ai prodotti cosmetici presenti nello store online di *Sephora* (catena internazionale di negozi di cosmetici) e contiene informazioni descrittive e commerciali relative a ciascun prodotto. Questo dataset consente di rappresentare le caratteristiche dei prodotti che verranno valutati dal modello.
- Il secondo file (**Reviews Dataset**) contiene alcune recensioni di utenti relative ai prodotti presenti nel catalogo. Oltre alle valutazioni espresse dagli utenti (rating numerico e indicazione di raccomandazione), il dataset include alcune caratteristiche personali dell'utente recensore.

L'unione di entrambi i file consente di associare, per ogni recensione, le caratteristiche dell'utente con quelle del prodotto recensito, creando così esempi utilizzabili per l'addestramento del modello volto a prevedere la compatibilità tra utente e prodotto cosmetico.

Analisi del Products Dataset

Il dataset dei prodotti (8.494 prodotti, 27 feature) fornisce una descrizione dettagliata delle caratteristiche dei cosmetici, tra cui:

- **Informazioni generali:** nome, brand, categoria
- **Caratteristiche commerciali:** prezzo, disponibilità, edizione limitata

Feature	Descrizione
product_id	Identificatore univoco del prodotto
product_name	Nome completo del prodotto
brand_id	Identificatore univoco del brand del prodotto
brand_name	Nome completo del brand del prodotto

loves_count	Numero di utenti che hanno contrassegnato il prodotto come preferito
rating	Valutazione media del prodotto basata sulle recensioni degli utenti
reviews	Numero totale di recensioni ricevute dal prodotto
size	Dimensione del prodotto (espressa in ml, g, confezioni o altre unità a seconda del tipo di prodotto)
variation_type	Tipo di parametro di variazione del prodotto (es. dimensione, colore)
variation_value	Valore specifico del parametro di variazione (es. 100 mL, Golden Sand)
variation_desc	Descrizione del parametro di variazione (es. tonalità per pelle molto chiara)
ingredients	Lista degli ingredienti del prodotto
price_usd	Prezzo del prodotto in dollari statunitensi
value_price_usd	Risparmio potenziale sul prezzo del prodotto, come indicato sul sito di Sephora
sale_price_usd	Prezzo scontato del prodotto in dollari statunitensi
limited_edition	Indica se il prodotto è in edizione limitata (1 = sì, 0 = no)
new	Indica se il prodotto è nuovo (1 = sì, 0 = no)
online_only	Indica se il prodotto è venduto esclusivamente online (1 = sì, 0 = no)
out_of_stock	Indica se il prodotto è attualmente esaurito (1 = sì, 0 = no)
sephora_exclusive	Indica se il prodotto è un'esclusiva Sephora (1 = sì, 0 = no)
highlights	Lista di tag o caratteristiche che evidenziano gli attributi del prodotto (es. "Vegan", "Finish opaco")
primary_category	Categoria principale del prodotto
secondary_category	Categoria secondaria del prodotto
tertiary_category	Categoria terziaria del prodotto
child_count	Numero di varianti disponibili per il prodotto
child_max_price	Prezzo massimo tra le varianti del prodotto

child_min_price	Prezzo minimo tra le varianti del prodotto
-----------------	--

Analisi del Reviews Dataset

Il dataset delle recensioni (602.130 righe, 19 feature) contiene:

- **Caratteristiche dell'utente:** informazioni come il tipo e il tono di pelle del recensore permettono di costruirne un profilo dell'utente.
- **Segnale di compatibilità (label):** la feature binaria *is_recommended* può essere considerata un indicativo della soddisfazione del cliente e, di conseguenza, della compatibilità del prodotto.

Feature	Descrizione
author_id	Identificatore univoco dell'autore della recensione sul sito
rating	Valutazione assegnata dall'utente al prodotto su una scala da 1 a 5
is_recommended	Indica se l'utente consiglia il prodotto (1 = sì, 0 = no)
helpfulness	Rapporto tra feedback positivi e feedback totali sulla recensione
total_feedback_count	Numero totale di feedback (positivi e negativi) ricevuti dalla recensione
total_neg_feedback_count	Numero di utenti che hanno assegnato un feedback negativo alla recensione
total_pos_feedback_count	Numero di utenti che hanno assegnato un feedback positivo alla recensione
submission_time	Data di pubblicazione della recensione nel formato "aaaa-mm-gg"
review_text	Testo principale della recensione scritto dall'utente
review_title	Titolo della recensione scritto dall'utente
skin_tone	Tono della pelle dell'utente (es. chiaro, medio, scuro)
eye_color	Colore degli occhi dell'utente
skin_type	Tipo di pelle dell'utente (es. secca, grassa, mista)
hair_color	Colore dei capelli dell'utente
product_id	Identificatore univoco del prodotto recensito sul sito

Integrazione dei due Dataset

Per poter utilizzare entrambi i dataset, è necessario collegarli in base a un elemento comune: la colonna ***product_id***, che rappresenta un identificatore unico per ogni prodotto e compare sia nel file dei prodotti che in quello delle recensioni.

Collegando i due dataset su questa chiave, è possibile creare esempi del tipo:

caratteristiche utente + caratteristiche prodotto → esito della recensione

Questo permetterà al modello di imparare quali prodotti sono più adatti a ciascun profilo utente.

Limiti

Il dataset selezionato, tuttavia, presenta alcune limitazioni, che è utile evidenziare:

- **Soggettività delle recensioni:** Il concetto di “adatto” dipende dall’opinione personale degli utenti. Non è una misura clinica, quindi il modello impara dalle preferenze degli utenti, non da dati dermatologici certificati.
- **Valori mancanti:** Alcune recensioni o caratteristiche degli utenti non sono complete. Saranno richiesti interventi di preprocessing per gestire eventuali assenze nei dati evitando di comprimere la qualità del modello.
- **Sbilanciamento delle classi:** Nei dataset di recensioni cosmetiche, la maggior parte delle valutazioni tende a essere positiva, portando a un disequilibrio tra le classi. Questo può rendere difficile l’identificazione di prodotti “non adatti” e richiede l’adozione di tecniche per gestire lo sbilanciamento e l’uso di metriche appropriate, come F1-score e precision/recall.
- **Generalizzabilità limitata:** I dati disponibili riflettono solo gli utenti e i prodotti presenti nel dataset. Prodotti o profili utente molto diversi da quelli osservati potrebbero non essere valutati correttamente dal modello, limitando la capacità di generalizzare a nuovi contesti.
- **Dipendenza dal contesto culturale o demografico:** Le preferenze cosmetiche possono variare in base a fattori culturali, geografici o demografici. Se il dataset non è rappresentativo di tutte le categorie di utenti, il modello potrebbe sviluppare bias impliciti, favorendo alcune caratteristiche rispetto ad altre.

Distribuzione dei Dati

Nella fase di analisi della distribuzione dei dati, verrà data maggiore attenzione alle **feature ritenute maggiormente rilevanti** e correlate al target *is_recommended*.

Distribuzione del Target

La variabile ***is_recommended*** viene utilizzata come target, interpretata come indicatore di compatibilità percepita.


- L’83,8% delle recensioni consiglia il prodotto (406.094 recensioni positive)
- Il 16,2% non lo consiglia (78.550 recensioni negative)

Come previsto, è presente un evidente e significativo **sbilanciamento delle classi**: la classe positiva è molto più rappresentata di quella negativa. Il modello potrebbe essere influenzato da questo sbilanciamento.

Distribuzione delle Feature dell’Utente

Feature skin_type

La feature *skin_type* è ritenuta rilevante perché diversi prodotti cosmetici sono più o meno adatti a ciascun tipo di pelle.




La **categoria più rappresentata** (**48.5%**) è *combination*, quasi metà del dataset.

C'è una percentuale significativa di **valori mancanti** (**12.4%**) che dovrà essere gestita nella fase di preprocessing.

Le categorie *normal*, *dry* e *oily* hanno una distribuzione abbastanza equilibrata tra di loro rispetto al totale, ma molto più bassa rispetto alla categoria *combination*.

Feature *skin_tone*

La feature *skin_tone* indica la tonalità della pelle dell'utente e può influenzare la scelta dei prodotti.



Le categorie più rappresentate sono *light*, *fair* e *lightMedium*, che insieme costituiscono circa **59%** del dataset.

I **valori mancanti** corrispondono a circa il **17%**, una percentuale di dati abbastanza significativa che necessiterà di gestione nelle fasi successive.

Molte categorie hanno **pochissimi esempi** (*rich*, *olive*, *porcelain*, *dark*, *notSureST*, *ebony*, *None*), e potrebbero essere:

- raggruppate in categorie più generiche
- considerate come “unknown” per il modello.


C'è una forte **sbilanciamento tra toni chiari e toni scuri**: il modello potrebbe avere difficoltà a imparare bene per le categorie poco rappresentate.

Distribuzione delle Feature dei Prodotti

Feature rating

Un prodotto con rating alto ha più probabilità di essere consigliato.


Nota: La feature non corrisponde al singolo voto di un utente, ma indica il rating medio calcolato sulle recensioni degli utenti per il singolo prodotto.



La **maggior parte dei prodotti** ha rating compreso tra **4 e 5**, 5.929 su 8.216 prodotti (~**72%**). Solo pochi prodotti hanno **rating basso** (sotto 3), circa il **3,4%**.

Feature reviews

La feature *reviews* è un indicatore della popolarità dei prodotti.



La distribuzione del numero di recensioni per prodotto è **fortemente asimmetrica**: la maggior parte dei prodotti ha meno di 500 recensioni (~6.448 su 8.216), mentre pochi prodotti raggiungono migliaia di recensioni.

Prodotti con molte recensioni possono essere percepiti come più affidabili, ma non sempre sono adatti a tutti i tipi di pelle: *reviews* va considerata come feature contestuale.

Missing Values

Reviews Dataset

Colonna	% missing
helpfulness	55,1%
eye_color	23%
hair_color	23,4%
is_recommended	19.5%
skin_tone	17.6%
review_title	27,7%
skin_type	12,4%
review_text	0,16%

Alcune feature presentano molti missing, ad esempio *helpfulness* (55%), *review_title* e *hair_color/eye_color*.

Le feature principali per il nostro modello, *skin_type* e *skin_tone*, hanno valori mancanti moderati.

Altre feature, come *rating*, hanno pochissimi missing e non rappresentano un problema.

Products Dataset

Colonna	% missing
sale_price_usd	96,8%
value_price_usd	94,7%
variation_desc	85,3%
child_max_price / child_min_price	67,6%
highlights	26%
size	19,2%
variation_value	18,8%
variation_type	17%
secondary_category	0.094%
tertiary_category	11,7%
ingredients	11,1%
rating, reviews	3,3%

Alcune colonne, come *sale_price_usd* e *value_price_usd*, presentano troppi valori mancanti e verranno escluse dall'analisi.


Le feature più rilevanti per il modello, *rating* e *reviews*, hanno pochi valori mancanti, che potranno essere gestiti in seguito.

Altre colonne con missing moderati (*size*, *variation_value*, *variation_type*, *tertiary_category*, *ingredients*) potranno essere ignorate per semplicità o trattate caso per caso.

Outliers


Alcuni dati, come *price_usd*, *child_max_price* o *child_min_price*, hanno un impatto meno evidente sul target *is_recommended*: la presenza di eventuali outlier in questa tipologia di feature non è considerata critica in questa fase.

Products Dataset




- Mediana ≈ 9.880
- Max $\approx 1.400.000$

Il box risulta concentrato sui valori più bassi, mentre centinaia o migliaia di prodotti particolarmente popolari (**bestseller**) vengono rappresentati come punti al di fuori del box. Ciò evidenzia una distribuzione fortemente asimmetrica con lunga coda destra.




- Mediana ≈ 122
- Max ≈ 21.281

Pochi prodotti accumulano un numero molto elevato di recensioni, mentre la maggior parte presenta valori contenuti. Anche in questo caso la distribuzione è fortemente sbilanciata e caratterizzata da una long-tail.



- Mediana ≈ 35
- Max ≈ 1.900


Il boxplot risulta schiacciato sui valori più bassi, con un outlier molto distante dal resto della distribuzione ma non necessariamente dovuto ad un errore: potrebbe trattarsi di un **prodotto luxury** venduto ad un prezzo superiore alla media.



- Mediana $\approx 4,29$
- Valori compresi tra 1 e 5

A differenza delle variabili precedenti, *rating* presenta una distribuzione limitata fortemente concentrata su valori medio-alti. Valori estremi (rating bassi) sono rari ma plausibili e non indicano anomalie. Non emergono outlier significativi tali da richiedere interventi di preprocessing.

Reviews Dataset



- Mediana: 5
- Valori compresi tra 1 e 5

La feature *rating* del *Reviews Dataset* ha distribuzione fortemente sbilanciata verso l'alto: almeno il 50% delle osservazioni ha rating uguale a 5, mentre i valori bassi (1–2) sono rari.

Non sono presenti veri outlier o anomalie: tutti i valori nel range sono plausibili.

Merge dei Datasets e Selezione delle Features

Prima di procedere all'integrazione dei due dataset (Reviews e Products), è stata effettuata un'analisi delle variabili disponibili, con l'obiettivo di selezionare esclusivamente le feature potenzialmente informative e coerenti con il problema affrontato. Questa fase permette di ridurre la complessità del dataset finale, limitare il rumore e facilitare le successive fasi di preprocessing e modellazione.

Sono state escluse principalmente:

- **Variabili puramente identificative**, che non apportano informazione predittiva (ad esempio identificatori o indici).
- **Variabili testuali non strutturate**, la cui analisi avrebbe richiesto tecniche di Natural Language Processing (NLP) non incluse nello scope del progetto.
- **Feature caratterizzate da un'elevata percentuale di valori mancanti**, tali da comprometterne l'utilità informativa.
- **Variabili ridondanti o poco rilevanti** rispetto all'obiettivo di previsione.

Feature escluse da Reviews Dataset

- *Unnamed: 0*: indice del dataset privo di significato informativo.
- *author_id*: identificatore dell'utente, non utile ai fini predittivi.
- *review_text* e *review_title*: contenuti testuali non strutturati.

- *submission_time*: informazione temporale non direttamente rilevante per la previsione della compatibilità del prodotto.
- *helpfulness*: caratterizzata da un'elevata percentuale di valori mancanti e da una bassa correlazione con la variabile target.
- *hair_color* ed *eye_color*: variabili con numerosi valori mancanti e con un contributo informativo limitato rispetto al problema considerato.
- *total_feedback_count*, *total_pos_feedback_count* e *total_neg_feedback_count*: queste informazioni non riguardano direttamente il prodotto o l'utente, ma rappresentano l'interazione degli utenti con una recensione *dopo* la sua pubblicazione.
- *product_name* e *brand_name*: rappresentano informazione ridondanti presenti anche in Products Dataset.

Feature escluse da Products Dataset

- *sale_price_usd* e *value_price_usd*: presenti in meno del 5% dei prodotti, quindi scarsamente informative.
- *variation_desc*, *variation_type*, *variation_value*: feature fortemente sparse e caratterizzate da un'elevata variabilità.
- *child_max_price*, *child_min_price* e *child_count*: disponibili solo per una parte dei prodotti e non particolarmente rilevanti.
- *size*: espressa in unità eterogenee e non facilmente confrontabili.
- *limited_edition*, *new*, *online_only*, *out_of_stock*, *sephora_exclusive*: flag binari con poco impatto sulla compatibilità.
- *brand_id*: id tecnico e ridondante, basta la feature *brand_name*
- *product_name*: ridondante, basta la feature *product_id* per identificare i prodotti.

Dopo la selezione delle feature, i due dataset sono stati integrati tramite un'operazione di merge di tipo **inner join** sulla chiave comune *product_id*. Questa scelta garantisce che il dataset finale includa esclusivamente osservazioni complete dal punto di vista informativo, ovvero recensioni associate a prodotti effettivamente presenti nel catalogo, evitando la propagazione di valori mancanti non necessari.

La selezione preliminare delle feature ha permesso di ottenere un dataset unificato più compatto e coerente. Formato da 602.130 righe e 16 colonne, specificate in seguito:

- **Da Review:** *user_rating*, *is_recommended*, *skin_tone*, *skin_type*, *review_price_usd*.
- **Da Product:** *product_id*, *brand_name*, *loves_count*, *avg_product_rating*, *reviews_count*, *product_price_usd*, *ingredients*, *highlights*, *primary_category*, *secondary_category*, *tertiary_category*.

Preprocessing

In una prima fase, è stata condotta un'analisi esplorativa separata sui due dataset (Products e Reviews) al fine di comprenderne struttura, qualità e criticità principali.

Ora, in seguito all'integrazione dei dataset, tali analisi saranno riprese sul dataset unificato e utilizzate come riferimento per le scelte di preprocessing e modellazione.

Questa scelta è dettata dal fatto che il processo di merging può alterare la distribuzione dei dati.

Gestione dei Missing Values

I valori mancanti sono stati gestiti in modo differenziato a seconda del ruolo della variabile.

Le osservazioni con target mancante (*is_recommended*) sono state rimosse, mentre per le variabili categoriali e testuali i valori mancanti sono stati interpretati come informazione potenzialmente rilevante e sostituiti con categorie esplicite (ad es. “*unknown*”, “*not_specified*”).

Variabile	Missing Count	Missing %	Tipo	Strategia	Motivazione
tertiary_category	116.500	19.35%	Categorica	Imputazione con categoria “ <i>not_specified</i> ”	La categorizzazione dei prodotti segue una struttura gerarchica (primary, secondary, tertiary), in cui il livello tertiary potrebbe rappresentare un dettaglio opzionale e non sempre specificato.
is_recommended	117.486	19.34%	Target	Rimozione di righe	Evita bias sul target
skin_tone	106.056	17.61%	Categorica	Imputazione con categoria “ <i>Unknown</i> ”	Il missing è plausibilmente informativo. Eliminare i record ridurrebbe le osservazioni a disposizione.
skin_type	74.683	12.40%	Categorica	Imputazione con categoria “ <i>Unknown</i> ”	Il missing è plausibilmente informativo. Eliminare i record ridurrebbe le osservazioni a disposizione.
highlights	50.230	8.34%	Testo	Imputazione con token “ <i>no_highlights</i> ”	Evita distorsioni del dataset: l'assenza del valore non è necessariamente dovuta a un errore di raccolta, ma può riflettere l'assenza di claim marketing associati al prodotto.
ingredients	9110	1.51%	Testo	Imputazione con token “ <i>unknown</i> ”	La percentuale di valori mancanti è bassa e la rimozione delle osservazioni comporterebbe una

					perdita di dati non necessaria.
--	--	--	--	--	---------------------------------

La shape del dataset in seguito alla gestione di tutti i valori mancanti è (484.644 , 16).

Trattamento Outliers

L'analisi delle variabili numeriche tramite boxplot, eseguita nella fase di EDA, ha suggerito che:

- Le variabili *user_rating*, *review_price_usd*, *product_price_usd* e *avg_product_rating* non presentano valori anomali significativi, pertanto non è necessario alcun intervento.
- Le variabili *loves_count* e *reviews_count* mostrano una distribuzione fortemente asimmetrica, con valori elevati che corrispondono a prodotti particolarmente popolari. Poiché tali valori costituiscono informazioni rilevanti per il modello, non vengono rimossi. Il loro impatto sugli algoritmi viene ridotto applicando una **trasformazione logaritmica**:

$$x_{\log1p} = \log(1 + x)$$

Encoding delle Variabili Categoriche

Feature skin_type

La variabile categorica *skin_type*, che può assumere i valori *unknown*, *dry*, *normal*, *combination* e *oily*, è stata trasformata tramite **Label Encoding**, generando un intervallo numerico compreso tra 0 e 4.

Feature skin_tone

Alcune categorie di *skin_tone* sono molto frequenti nel dataset, come *light*, *fair*, *medium*, *tan*, *deep*, *dark* e *unknown*, mentre altre compaiono più raramente, ad esempio *lightMedium*, *mediumTan*, *fairLight*, *rich*, *porcelain*, *olive*, *notSureST*, *ebony*.

Un numero elevato di categorie può aumentare il rischio di **overfitting** e rendere più difficile per il modello cogliere pattern significativi. Per semplificare e bilanciare la variabile, le categorie sono state raggruppate in **macro-categorie semantiche** basate sulla luminosità della pelle:

- **VERY FAIR (Molto chiaro):** porcelain, fair, fairLight
- **LIGHT (Chiaro):** light, lightMedium
- **MEDIUM (Medio):** medium, olive
- **TAN (Abbronzato/Scuro chiaro):** mediumTan, tan
- **DEEP (Scuro):** deep, dark, rich, ebony
- **UNKNOWN (Non specificato):** unknown, notSureST

In questo modo, le 15 categorie originali vengono ridotte a **6 categorie bilanciate**, preservando l'informazione semantica principale.

Successivamente, si applica **Label Encoding**, mappando ciascuna macro-categoria in un numero intero da 0 a N.

Feature brand_name

Dall'analisi esplorativa è emerso che il numero di brand distinti è relativamente elevato (circa 60), con una distribuzione fortemente sbilanciata: pochi brand sono molto frequenti, mentre molti altri compaiono raramente.

Un encoding diretto di tutte le categorie avrebbe potuto introdurre rumore e favorire problemi di overfitting. Per ridurre la complessità sono stati selezionati i **30 brand più frequenti** nel dataset,

mentre tutti gli altri brand meno rappresentati sono stati raggruppati in un'unica categoria denominata **Other**. Il risultato è una nuova variabile categoriale (*brand_top*) con 31 categorie totali. Successivamente, la variabile *brand_top* è stata trasformata tramite **label encoding**: a ciascuna categoria è stato assegnato un identificativo numerico intero.

In parallelo, è stata creata tramite **frequency encoding** una nuova feature, *brand_freq*, che, per ogni osservazione, indica quante volte il brand compare nel dataset. Questa variabile fornisce una nuova informazione utile al modello riguardo alla “popolarità” del brand.

Features riguardo alle categorie di prodotti

Il dataset include tre livelli di categorizzazione dei prodotti:

- **primary_category**: contiene una sola categoria (“Skincare”) per tutti i prodotti; quindi, non apporta informazione utile al modello ed è stata rimossa.
- **secondary_category**: include 10 categorie, come “Moisturizers”, “Cleansers”, “Serums”, ecc.
- **tertiary_category**: include 19 categorie più dettagliate, ad esempio “Face Creams”, “Gel Cleansers”, ecc.

Per entrambe le feature rimanenti, è stato applicato un **label encoding** separato. In questo modo ogni categoria viene mappata a un numero intero unico.

Selezione delle Feature

Dopo la fase di pulizia dei dati, il dataset risultante non presenta valori mancanti ed include variabili numeriche trasformate tramite logaritmo per la gestione degli outlier, oltre a variabili categoriche opportunamente codificate. A partire da questo dataset preprocessato, viene definita una prima configurazione di modello baseline, con l'obiettivo di stabilire un riferimento prestazionale iniziale.

Per la selezione delle feature utili alla costruzione del modello baseline sono state applicate le seguenti scelte:

- Sono state **escluse le variabili testuali** *ingredients* e *highlights*.
- Sono stati esclusi gli **identificativi puri**, come *product_id*, poiché non contengono informazione predittiva utile.
- Per le variabili categoriche, sono state utilizzate **solo le versioni già encodeate**, escludendo le colonne categoriche originali in formato testuale, al fine di evitare ridondanze.
- Per le variabili di conteggio (*loves_count* e *reviews_count*) sono state utilizzate esclusivamente le **versioni trasformate** (log) già calcolate, al fine di ridurre la skewness delle distribuzioni.
- La variabile ***user_rating*** è stata esclusa per prevenire fenomeni di **information leakage**. Tale variabile è fortemente correlata alla variabile target *is_recommended*, e il suo utilizzo potrebbe portare a una stima eccessivamente ottimistica delle prestazioni del modello, non rappresentativa della reale capacità predittiva.

Sulla base di questi criteri, il modello baseline utilizza le seguenti feature:

<i>is_recommended (target)</i>	<i>loves_count_log</i>	<i>skin_tone_encoded</i>
<i>review_price_usd</i>	<i>reviews_count_log</i>	<i>brand_top_encoded</i>
<i>product_price_usd</i>	<i>brand_freq</i>	<i>secondary_category_encoded</i>
<i>avg_product_rating</i>	<i>skin_type_encoded</i>	<i>tertiary_category_encoded</i>

Split del Dataset (Train, Validation, Test)

Il dataset è stato suddiviso in tre insiemi distinti:

- **Training set (70%)**: utilizzato per l'addestramento del modello, ovvero per l'apprendimento dei pattern presenti nei dati.
- **Validation set (15%)**: utilizzato per la sintonizzazione degli iperparametri del modello e per il controllo del fenomeno di overfitting. Il modello non ha accesso a questi dati durante l'addestramento, garantendo una valutazione imparziale.
- **Test set (15%)**: utilizzato esclusivamente per la valutazione finale delle prestazioni del modello. Questo insieme rappresenta dati "non visti" dal modello e consente un confronto affidabile tra modelli baseline e avanzato.

Come visto in precedenza, la variabile target *is_recommended* presenta uno sbilanciamento, con più osservazioni positive che negative. Lo split in training, validation e test è stato effettuato in modo **stratificato** per preservare le proporzioni nei tre insiemi (ogni insieme ha la stessa percentuale di prodotti raccomandati e non raccomandati del dataset originale). Eventuali tecniche di ribilanciamento saranno applicate solo sul training set, mentre validation e test set manterranno la distribuzione naturale per una valutazione imparziale delle prestazioni del modello.

Scaling delle Variabili Numeriche

Per garantire che tutte le feature numeriche fossero comparabili, è stata applicata una **standardizzazione** tramite lo **StandardScaler** di *scikit-learn*.

Le feature numeriche interessate dallo scaling sono: *review_price_usd*, *brand_freq*, *product_price_usd*, *avg_product_rating*, *loves_count_log* e *reviews_count_log*.

Lo scaler è stato **fit solo sul training set**, calcolando media e deviazione standard delle variabili numeriche. Successivamente, lo stesso scaler è stato utilizzato per trasformare validation e test set, assicurando che le trasformazioni fossero basate esclusivamente sui dati di training e prevenendo qualsiasi fenomeno di **data leakage**.

$$x_{\text{scaled}} = \frac{x - \text{mean}(\text{train})}{\text{std}(\text{train})}$$

Questo processo ha portato le feature numeriche ad avere **media pari a 0** e **deviazione standard pari a 1**.

Bilanciamento del Training Set

La variabile target *is_recommended* presenta circa l'84% di prodotti raccomandati e il 16% di prodotti non raccomandati. In presenza di questo sbilanciamento, il modello potrebbe imparare a predire quasi sempre la classe dominante, trascurando la minoritaria.

Per mitigare questo effetto, nel modello baseline verrà adottata la strategia **Class weight a livello di algoritmo**: verrà utilizzato un modello di classificazione con il parametro ***class_weight='balanced'***. Questo assegna automaticamente un peso maggiore agli errori sulla classe minoritaria e un peso minore agli errori sulla classe dominante, bilanciando l'importanza delle due classi durante il training.

In questo modo:

1. Il training del modello diventa sensibile anche alla classe minoritaria.
2. Non è necessario modificare i dati di validation e test, che restano nella loro distribuzione naturale.
3. L'addestramento resta semplice e stabile, senza duplicazioni di dati o rischio di overfitting artificiale.

In aggiunta, la valutazione del modello verrà effettuata tramite metriche robuste allo sbilanciamento.

Modello e Scelte Progettuali

L'obiettivo del progetto è la classificazione binaria della variabile *is_recommended*.

Per la fase iniziale (baseline) sono stati considerati due modelli principali:

Logistic Regression

La **Logistic Regression** è un modello di classificazione binaria.

Come funziona:

- Analizza tutte le feature e calcola un punteggio che sintetizza l'effetto combinato delle variabili sul target.
- Trasforma questo punteggio nella probabilità che l'osservazione appartenga alla classe positiva (*is_recommended* = 1).
- Confronta la probabilità con una soglia (0.5) per decidere la classe finale.

Perché è stata scelta:

- È **semplice e interpretabile**: ogni coefficiente indica l'impatto della feature sul target.
- Funziona bene come baseline: permette di avere un riferimento chiaro prima di provare modelli più complessi.
- Supporta il bilanciamento delle classi tramite il parametro **class_weight='balanced'**, utile dato lo sbilanciamento del target.
- È adatto a feature numeriche e categoriali codificate.

Il modello è stato creato con solver **liblinear**, ottimale per dataset medio-piccoli e classificazione binaria.

Random Forest

La **Random Forest** è un modello di **ensemble learning** basato su alberi decisionali.

Come funziona:

- Vengono creati molti alberi decisionali su sottoinsiemi casuali del training set (**bootstrap sampling**) e delle feature (**feature bagging**).
- Ogni albero predice la classe dell'osservazione.
- La Random Forest **aggrega le predizioni degli alberi tramite votazione maggioritaria**.
- La casualità introdotta riduce il rischio di overfitting e aumenta la capacità del modello di generalizzare su dati nuovi.

Perché è stata scelta:

- **Riduce il rischio di overfitting** rispetto a un singolo albero, producendo previsioni più accurate e stabili.
- Permette di ottenere importanza delle feature, utile per capire quali variabili influenzano maggiormente il target.
- Funziona come modello avanzato di confronto rispetto alla Logistic Regression, permettendo di migliorare predizioni su **target sbilanciati** e **pattern non lineari**.

Parametri:

- **n_estimators=100**: 100 alberi, un buon compromesso tra precisione e tempo di calcolo.
- **max_depth=None**: gli alberi possono crescere fino a completa separazione dei dati.

Random Forest è un modello più flessibile della Logistic Regression, capace di catturare relazioni non lineari tra le feature. Questo la rende adatta per stabilire un confronto e valutare eventuali miglioramenti prestazionali derivanti dalla cattura di pattern più complessi.

Valutazione Iniziale delle Prestazioni

Per valutare le performance del modello sono state considerate le seguenti metriche:

Metrica	Logistic Regression	Random Forest
Accuracy	0.6143	0.5959
Precision	0.8823	0.8819
Recall	0.6228	0.5978
F1-score	0.7302	0.7126
ROC AUC	0.6354	0.6262

Logistic Regression	Actually Positive	Actually Negative
Predicted Positive	37.939	5.063
Predicted Negative	22.975	6.720

Random Forest	Actually Positive	Actually Negative
Predicted Positive	36.416	4.877
Predicted Negative	24.498	6.906

- **Accuracy:** indica la percentuale di predizioni corrette sul totale dei casi. Data la distribuzione sbilanciata verso le recensioni positive, questa metrica da sola non è sufficiente per valutare la capacità del modello di distinguere utenti compatibili da utenti meno compatibili.
- **Precision:** misura la proporzione di predizioni "Recommended" corrette rispetto a tutte le predizioni "Recommended". Per entrambi i modelli, assume il valore di circa l'**88%**: il modello è affidabile nel predire quando un utente sarà compatibile con il prodotto.
- **Recall:** indica la proporzione di utenti effettivamente compatibili catturati dal modello. Il modello individua solo il **62%** dei casi realmente compatibili, perdendo alcuni utenti che avrebbero potuto essere compatibili con il prodotto.
- **F1-score:** media armonica di precision e recall (**≈0.73**).
- **ROC AUC:** misura quanto il modello distingue utenti compatibili da non compatibili. Con valori **≈0.64**, il modello discrimina meglio del caso, ma ci sono margini di miglioramento.

- **Confusion Matrix:** mostra che il modello identifica bene utenti compatibili (veri positivi), ma fatica a distinguere completamente quelli non compatibili (falsi negativi).

Con `class_weight='balanced'` le performance baseline evidenziano il problema tipico dei **dataset sbilanciati**:

- **Precision elevata:** quando il modello predice "Recommended", ha ragione l'88% delle volte (pochi falsi positivi).
- **Recall Class 0 bassa:** il modello fatica a identificare prodotti "Not Recommended" (classe minoritaria). Solo il 57% dei "Not Recommended" viene rilevato (43% di falsi negativi: prodotti non adatti classificati come adatti).
- **ROC-AUC (0.635):** capacità discriminativa limitata ma superiore al random guess (0.50).

Lo sbilanciamento 84/16 porta il modello a favorire la classe maggioritaria, risultando in molti falsi negativi per la classe minoritaria.

Tra i modelli baseline considerati, la **Logistic Regression** ha ottenuto risultati leggermente migliori rispetto alla Random Forest, in particolare in termini di F1-score e ROC AUC. Questo risultato può apparire controintuitivo, in quanto modelli non lineari come la Random Forest sono generalmente in grado di catturare relazioni più complesse tra le feature.

Il fatto che un modello più complesso non migliori le prestazioni indica che il limite principale del sistema potrebbe essere dovuto ad altre caratteristiche del problema:

- le **relazioni tra le caratteristiche dell'utente e del prodotto** sono deboli o solo parzialmente catturate dalle feature disponibili;
- le **etichette del dataset** potrebbero essere affette da un livello significativo di rumore. La variabile target (`is_recommended`) è derivata da fonti soggettive (recensioni degli utenti).

Gestione dello Sbilanciamento

Per verificare se lo sbilanciamento del target fosse la causa principale delle performance limitate, sono state esplorate due strategie alternative.

SMOTE (Synthetic Minority Over-sampling Technique)

SMOTE è stato applicato esclusivamente al training set, dopo lo split dei dati, generando esempi sintetici della classe minoritaria fino a ottenere una distribuzione perfettamente bilanciata.

Balanced Random Forest

È stata inoltre testata una **Balanced Random Forest**, variante della Random Forest che invece di usare tutto il dataset (sbilanciato) o creare dati sintetici (SMOTE) riequilibra automaticamente le classi ad ogni albero. In questo modo, ogni albero viene addestrato su un sottoinsieme bilanciato del training set.

Confronto dei Risultati sul Validation Set (LR, RF, LR+SMOTE, BRF)

La valutazione successiva, effettuata sullo stesso validation set per garantire un confronto equo, ha prodotto i seguenti risultati:

Modello	Accuracy	Precision	Recall	F1-score	ROC AUC
---------	----------	-----------	--------	----------	---------

Logistic Regression	0.6143	0.8823	0.6228	0.7302	0.6354
Logistic Regression + SMOTE	0.6142	0.8810	0.6239	0.7305	0.6349
Random Forest	0.5959	0.8819	0.5978	0.7126	0.6262
Balanced Random Forest	0.5802	0.8854	0.5732	0.6959	0.6278

Effetto di SMOTE

- Recall: **+0.0011** (trascurabile)
- F1-score: **+0.0003** (trascurabile)
- ROC AUC: lieve peggioramento

Random Forest vs Balanced Random Forest

- precision leggermente più alta
- recall e F1 peggiori

Il confronto tra modelli ha mostrato che la **Logistic Regression senza SMOTE** resta il modello con le migliori performance complessive (miglior compromesso tra precision, recall e F1; ROC AUC più alto). Questo suggerisce che:

- Strategie di riequilibrio non hanno prodotto benefici significativi: lo **sbilanciamento del dataset non rappresenta il principale collo di bottiglia**;
- il limite principale potrebbe risiedere nell'**informatività delle feature disponibili**;
- la natura soggettiva del target introduce probabilmente **rumore nelle etichette**, riducendo il massimo livello di performance raggiungibile.

Prestazioni del Modello sul Test Set (LR)

Metriche del modello Logistic Regression senza SMOTE valutate sul test set finale:

Accuracy	Precision	Recall	F1-score	ROC AUC
0.613	0.882	0.621	0.729	0.636

Confusion Matrix	Actually Positive	Actually Negative
Predicted Positive	37.803	23.112
Predicted Negative	5.052	6.730


Accuracy ~61%: Non particolarmente alta ma inferiore alla percentuale di positivi (83.8%), quindi il modello bilancia bene classi positive e negative.

Precision alta (0.88): Questo è il punto più forte del modello. Quando il modello predice positivo, quasi 9 volte su 10 è corretto.

Recall moderato (0.62): Cattura circa 62% dei veri positivi.

F1-score ~0.73: Buon compromesso tra precision e recall.

ROC AUC ~0.636: valore piuttosto basso, separa le classi solo di poco meglio del caso. Allo stesso tempo, però, indica che il modello ha capacità discriminativa: le limitate performance osservate finora potrebbero non dipendere dall'assenza di segnale.



Le differenze tra le performance osservate sul validation set e quelle ottenute sul test set risultano dell'ordine di pochi decimi di punto percentuale e possono quindi essere considerate **trascurabili**. Questo indica l'**assenza di fenomeni di overfitting**: il modello non si adatta in modo specifico ai dati di validazione, ma mantiene prestazioni coerenti anche su dati non osservati. Nel complesso, il modello mostra una **buona capacità di generalizzazione**, risultando stabile e affidabile nel contesto applicativo considerato.

Threshold Tuning

I modelli inizialmente valutati (Logistic Regression, Random Forest e varianti bilanciate) hanno mostrato performance moderate, con una **precision elevata ma recall relativamente basso**: questo suggeriva che il modello fosse **eccessivamente conservativo**, privilegiando la precision a discapito della capacità di intercettare i casi positivi.

Nel contesto della cosmetica, sia i falsi positivi che i falsi negativi rappresentano errori, ma con **impatti differenti**.

I **falsi positivi**, ovvero la raccomandazione di prodotti non pienamente compatibili con il profilo dell'utente, possono comportare:

- una riduzione della fiducia nel sistema;
- potenziali effetti indesiderati sulla pelle, soprattutto in presenza di caratteristiche sensibili.

Tuttavia, la mancata raccomandazione di prodotti effettivamente compatibili (**falsi negativi**) potrebbe comportare:

- una perdita di opportunità di raccomandazione per l'utente;
- una riduzione del valore del sistema in termini di utilità e completezza;
- una riduzione delle vendite per i prodotti non raccomandati, con conseguente perdita economica.

Si rende quindi necessaria una **ricerca del miglior compromesso tra precision e recall** (trade-off tra falsi positivi e falsi negativi).

Valutazione delle Soglie sul Validation Set

La **Logistic Regression** è un modello probabilistico che produce, per ogni osservazione, una probabilità di appartenenza alla classe positiva. La decisione finale dipende dalla **soglia** utilizzata per convertire tale probabilità in una classe binaria.

La soglia standard di **0.5 non è necessariamente ottimale**, soprattutto in presenza di **dataset sbilanciati**. Si decide quindi di condurre un'analisi di **threshold tuning**, valutando soglie comprese tra 0.10 e 0.85.

Threshold	Precision	Recall	F1-score
0.10	0.838	1.000	0.912
0.15	0.839	0.998	0.912
0.20	0.841	0.990	0.909
0.25	0.843	0.982	0.907
0.30	0.845	0.972	0.904
0.35	0.849	0.938	0.891
0.40	0.858	0.865	0.862
0.45	0.868	0.765	0.813
0.50 (default)	0.882	0.623	0.730
0.55	0.898	0.458	0.607
0.60	0.912	0.293	0.443
0.65	0.928	0.145	0.251
0.70	0.952	0.046	0.087
0.75	0.970	0.011	0.022
0.80	0.750	0.000	0.000
0.85	0.000	0.000	0.000

Con soglia 0.10 il modello raggiunge un *recall massimo di 1.0*, quindi tutti i prodotti compatibili vengono identificati, ma la precisione è minore (0.838).

Aumentando la soglia a 0.15, il recall rimane molto alto (0.998) e la precision cresce leggermente a 0.839, con F1-score massimo di 0.912, riducendo leggermente i falsi positivi.

Con soglia **0.20**, il recall scende leggermente a 0.990 mentre la precisione aumenta a 0.841; l'F1-score rimane alto (0.909), rappresentando il **miglior compromesso complessivo** tra sicurezza dell'utente e opportunità di raccomandazione.

Confronto dei Risultati sul Test Set (LR con diverse soglie)

Performance finali sul test set:

Threshold	Precision	Recall	F1
0.50	0.882	0.621	0.729
0.20	0.841	0.989	0.909

- la **precision** diminuisce leggermente (-4.1%) $\rightarrow$ ancora robusta.
- il **recall** aumenta drasticamente ($+59\%$) $\rightarrow$ estremamente elevato.
- l'**F1-score** migliora in modo sostanziale, passando da 0.729 a 0.909.

La **confusion matrix** ottenuta con soglia 0.20 è la seguente:

Confusion Matrix con soglia 0.20	Actually Positive	Actually Negative
Predicted Positive	60.278	11.411
Predicted Negative	637	371

Confusion Matrix con soglia 0.50	Actually Positive	Actually Negative
Predicted Positive	37.803	23.112
Predicted Negative	5.052	6.730

Abbassando la soglia decisionale da 0.50 a 0.20, quindi:

- il modello diventa più permissivo nel classificare esempi come positivi, riducendo i falsi negativi (da 5.052 a 637) e intercettando quasi tutti i casi realmente compatibili (precision ancora elevata).
- Si registra un aumento dell'F1-score, che sintetizza efficacemente il compromesso tra le precision e recall.

Questo comportamento è coerente con la distribuzione del dataset: molte istanze della classe positiva presentano probabilità predette comprese tra **0.20 e 0.49**, che con soglia 0.5 verrebbero erroneamente classificate come negative.

Le performance inizialmente limitate **non erano dovute all'assenza di segnale nel modello**, ma principalmente a una **scelta non ottimale della soglia decisionale**.

La **ROC AUC** non è stata utilizzata per la scelta della soglia decisionale, in quanto tale metrica valuta la capacità discriminativa complessiva del modello indipendentemente dalla soglia (valuta se i casi realmente positivi ricevono, in media, probabilità più elevate rispetto ai casi negativi). Poiché il threshold tuning modifica esclusivamente la regola decisionale e non le probabilità predette, il valore di ROC AUC rimane invariato al variare della soglia.

Considerazioni finali e Sviluppi Futuri

L'analisi condotta ha permesso di evidenziare diversi aspetti chiave:

1. **Sbilanciamento del target e importanza della soglia**
 - La scelta della soglia decisionale ha un impatto rilevante sulle performance. Abbassando la soglia da 0.5 a 0.2, il modello intercetta quasi tutti i prodotti realmente compatibili (recall ~ 0.99) mantenendo una precision ancora elevata (~ 0.84).

- Questo compromesso è coerente con l'obiettivo di sicurezza dell'utente, minimizzando i falsi negativi pur controllando i falsi positivi.
- L'applicazione di SMOTE sul training set ha mostrato che il miglioramento delle performance non deriva esclusivamente dal bilanciamento dei dati, ma anche dalla scelta ottimale della soglia e dalla capacità discriminativa intrinseca del modello.
- Questo sottolinea un punto critico nel dominio: molti prodotti realmente compatibili hanno punteggi probabilistici moderati (0.2–0.49). Usare la soglia di default 0.5 penalizzerebbe fortemente sia l'utente che il venditore, approvando meno prodotti rilevanti.

2. Qualità del modello

- La ROC AUC indica una buona capacità discriminativa, ma non riflette la qualità reale della raccomandazione, perché il vero impatto è legato alla soglia scelta.
- La Logistic Regression risulta robusta e interpretabile, mentre Random Forest e Balanced Random Forest non hanno fornito vantaggi significativi in questo contesto.

3. Distribuzione dei dati e limiti

- Il dataset presenta ancora alcune limitazioni, come possibili bias legati a caratteristiche di utenti o prodotti non osservate, che potrebbero influenzare le raccomandazioni.
- Alcuni falsi positivi e falsi negativi potrebbero derivare non da errori del modello, ma da limiti intrinseci dei dati disponibili. Questo è particolarmente rilevante nel dominio cosmetico, dove la compatibilità dei prodotti può dipendere da fattori non osservati (es. allergie, preferenze personali).

Sviluppi Futuri nel Contesto Applicativo

- **Approfondimento delle feature:** includere variabili aggiuntive, descrizioni testuali o immagini dei prodotti, potrebbero permettere di catturare meglio le caratteristiche rilevanti per la compatibilità cutanea.
- **Personalizzazione delle soglie:** valutare soglie diverse per segmenti di utenti o categorie di prodotti (ad esempio, prodotti delicati vs. prodotti più generici) può ottimizzare la soddisfazione dell'utente.
- **Modelli avanzati con interpretabilità:** esplorare modelli ensemble o reti neurali con strumenti di interpretabilità, così da bilanciare performance e trasparenza.
- **Validazione con feedback reale:** raccogliere dati post-acquisto o valutazioni degli utenti per verificare se le raccomandazioni effettivamente migliorano l'esperienza di acquisto e la sicurezza dell'utente.

In sintesi, il modello sviluppato offre una base solida per raccomandazioni affidabili, con ampi margini di miglioramento attraverso dati più ricchi, modelli più sofisticati e tecniche avanzate per aumentare la soddisfazione e la sicurezza degli utenti.